

Oficina: Tratamento de Dados na Prática

Bem-vindos à nossa oficina de tratamento de dados! O objetivo deste projeto é demonstrar, de forma prática, como transformar uma base de dados "bruta" e inconsistente em uma base limpa, estruturada e pronta para análises.

Objetivo do Projeto

O foco desta atividade é capacitar os participantes a identificar erros comuns em conjuntos de dados do mundo real (valores nulos, formatações incorretas, duplicatas) e aplicar técnicas de limpeza utilizando a biblioteca **Pandas** em Python.

Etapas da Oficina

Dividimos o processo de tratamento de dados em cinco etapas fundamentais:

1. **Diagnóstico Inicial:** Carregamento da base bruta e análise exploratória para identificar as inconsistências (valores ausentes, tipos de dados errados).
2. **Limpeza Básica:** Remoção de registros duplicados e tratamento de valores nulos (decidindo entre remover ou preencher os dados).
3. **Padronização de Dados:** Ajuste de formatos de texto (limpeza de espaços, padronização de maiúsculas/minúsculas) e conversão de colunas para os tipos corretos (ex: texto para número).
4. **Validação:** Verificação da integridade da nova base de dados após o tratamento.
5. **Exportação e Reprodutibilidade:** Salvamento dos dados limpos e documentação do código para que outros possam reproduzir o resultado.

Comandos Essenciais (Kit de Sobrevivência)

Durante a oficina, utilizaremos os seguintes comandos da biblioteca pandas:

Comando	Finalidade
<code>df.info()</code>	Exibe o resumo da estrutura do DataFrame e os tipos de dados.
<code>df.isnull().sum()</code>	Conta quantos valores nulos existem em cada coluna.
<code>df.drop_duplicates()</code>	Remove registros duplicados.
<code>df.dropna()</code> / <code>df.fillna()</code>	Remove ou preenche valores nulos.
<code>df['coluna'].str.strip()</code>	Remove espaços em branco indesejados no início ou fim dos textos.
<code>df['coluna'].astype(tipo)</code>	Converte o tipo de dado de uma coluna (ex: de string para float).

Como Reproduzir

Todo o código utilizado está disponível neste repositório. Para executar:

1. Clone este repositório.
2. Certifique-se de ter o Python instalado com a biblioteca Pandas (``pip install pandas``).
3. Execute o script ``tratamento.py`` para gerar a versão limpa do dataset.
4. Compare ``dados_brutos.csv`` com ``dados_tratados.csv``.

Esta atividade é uma excelente oportunidade para entender o fluxo real de trabalho em Engenharia e Análise de Dados.